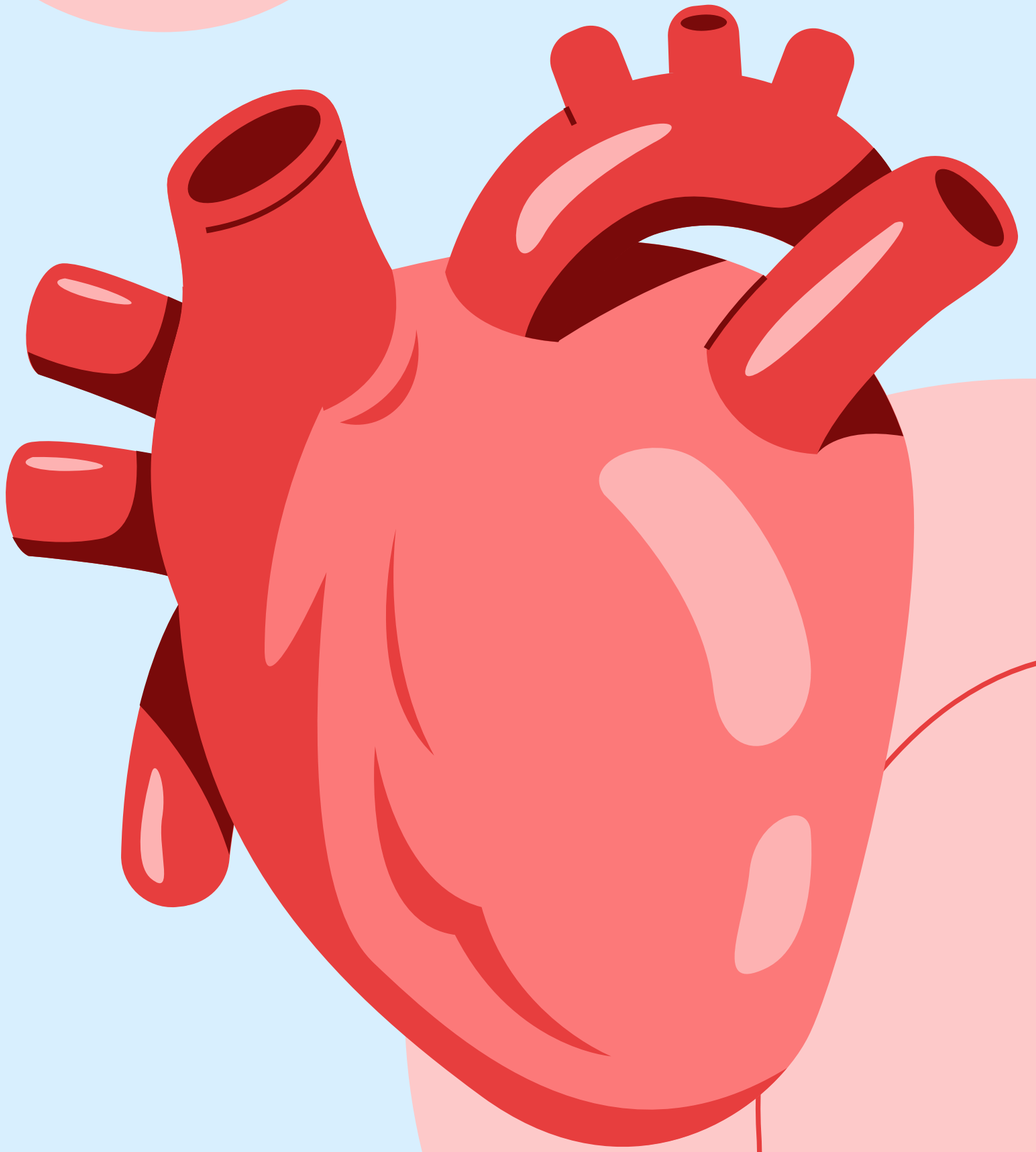
Equipo Salud

Adolph, Echeverry y Zerbino



Contenido

01 El problema y objetivos

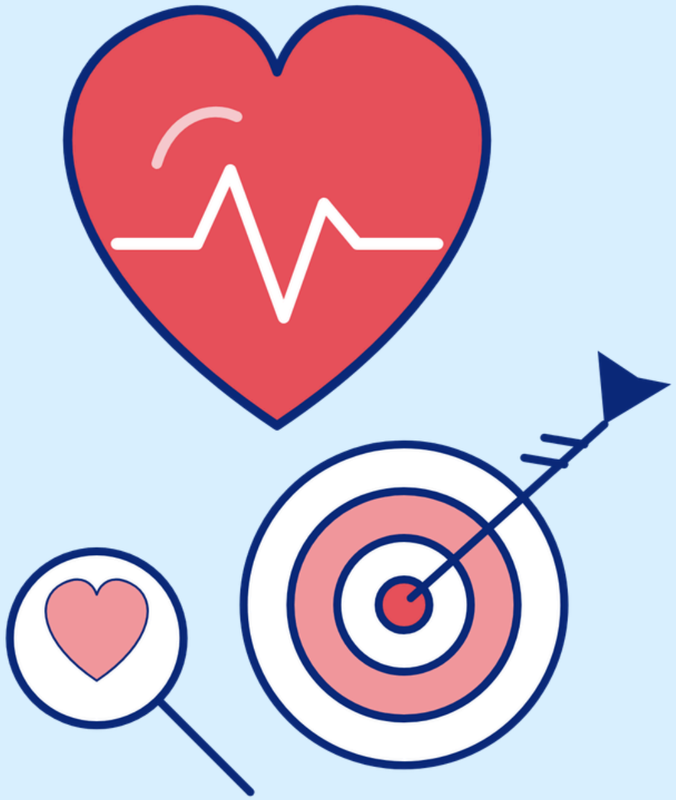
02 Datos

03 Limpieza y variables nuevas

04 Graficos

05 Modelo

06 Conclusiones y limitaciones



01

El problema y objetivos

Problema a resolver y objetivos

Problema

las enfermedades cardiovasculares son una de las principales causas de muerte, y detectarlas a tiempo permite prevenir.

Objetivo 1

identificar qué variables clínicas y de estilo de vida se asocian con la enfermedad.

Objetivo 2

construir un modelo que estime la probabilidad de que un paciente tenga ECV.

¿Es posible identificar patrones en los datos clínicos y de estilo de vida de un paciente que permitan predecir la presencia de una enfermedad cardiovascular?





02

Como son los datos

“**Cardiovascular Disease dataset**”, de Svetlana Ulianova, actualizado por última vez hace 8 años. Combina información dada por el paciente, resultados de exámenes médicos y la variable objetivo.

70.000

registros de distintos pacientes

11

características que describen a cada uno

1

variable objetivo: presenta o no la enfermedad

Cada paciente está identificado por un número único.

INT

Números enteros

Edad (en días), altura (en cm), presión arterial sistólica y presión arterial diastólica.

FLOAT

Decimales

Peso (en kg).

1 / 0

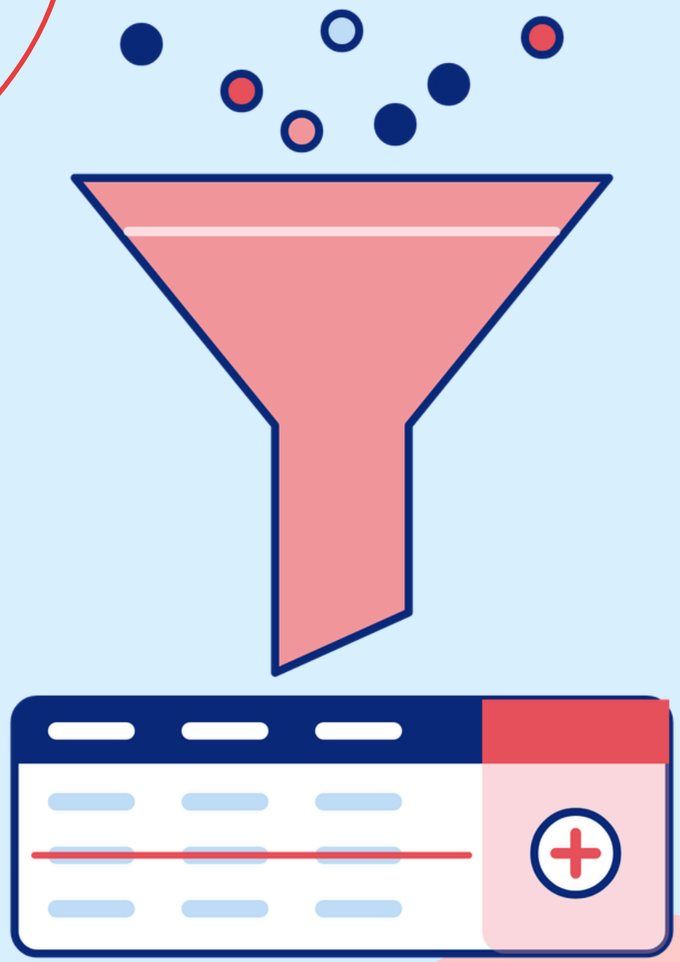
Binarios

Fumar, consumo de alcohol, actividad física y la característica objetivo: 1 indica que la condición aplica y 0 que no aplica.
Género: 1 (mujer), 2 (hombre).

1-2-3

Códigos categóricos

Colesterol y glucosa: 1 (normal), 2 (por encima de lo normal), 3 (muy por encima de lo normal).



03

Limpieza y variables nuevas

Limpieza de datos

70.000
Registros iniciales

→

68.618
Registros finales

Altura y peso fuera de rango — **60 eliminados**

Establecimos limites: altura = (120 - 220 cm), peso = (30 - 200 kg)

Presiones inconsistentes — **1.231 eliminados**

Presión diastolica mayor a la sistólica, medicamente imposible

Presiones fuera de rango — **91 eliminados**

Establecimos limites: sistólica = (60 - 250 mmHg), diastólica = (40 - 200 mmHg)

Tranformación y creación de variables

Variables utilizadas para explorar los datos

Edad en años y grupos de edad:
Conversión de días a años (÷365,25) y agrupación por intervalos

IMC y categoría de IMC:
Peso / altura^2, clasificado en 6 categorías: bajo peso, normal, sobrepeso y tres niveles de obesidad

Categoría de presión arterial:
Clasificación en 6 niveles combinando presión sistólica y diastólica, desde hipotensión hasta crisis hipertensiva

Presión de pulso:
Diferencia entre presión sistólica y diastólica

Variables que probamos, pero aportaron poco

Hábitos de riesgo:
Suma de fumar, consumir alcohol y no realizar actividad física

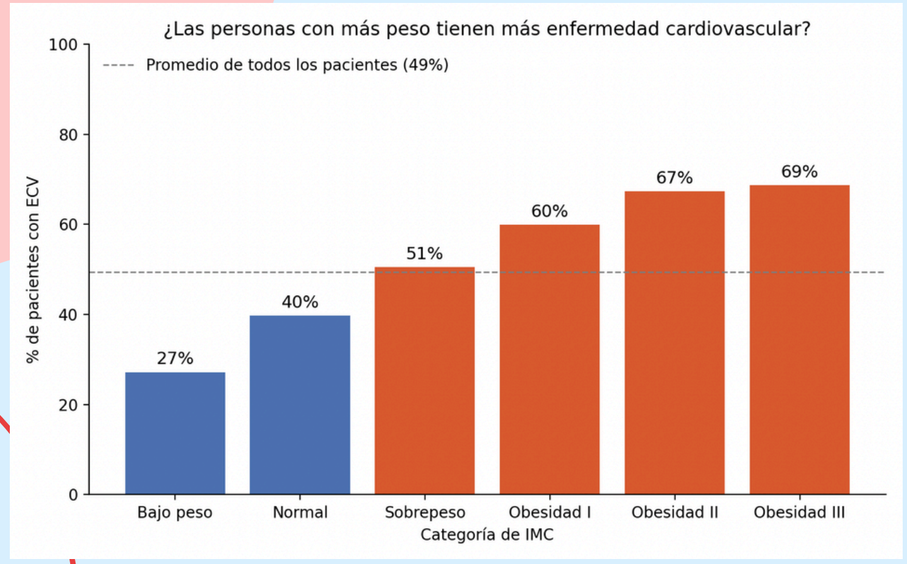
Suma de colesterol y glucosa:
Variable llamada *sindrome_metabolico* en el código. No mostró una mejora relevante en el análisis

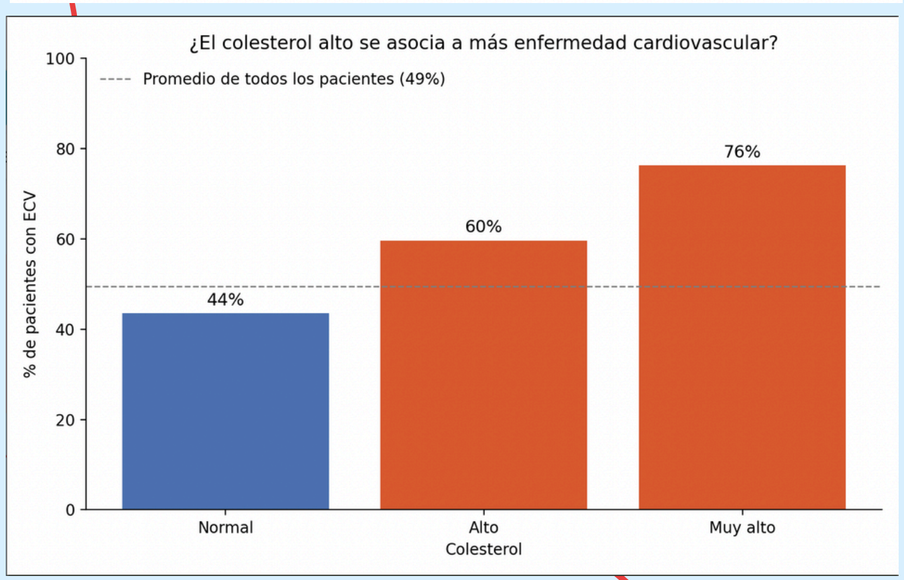


04

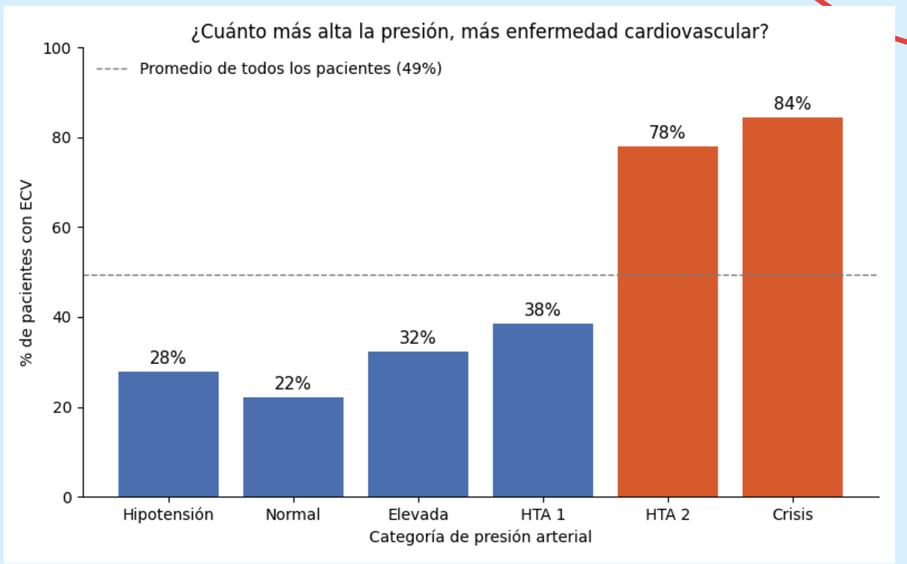
Presentación de gráficos

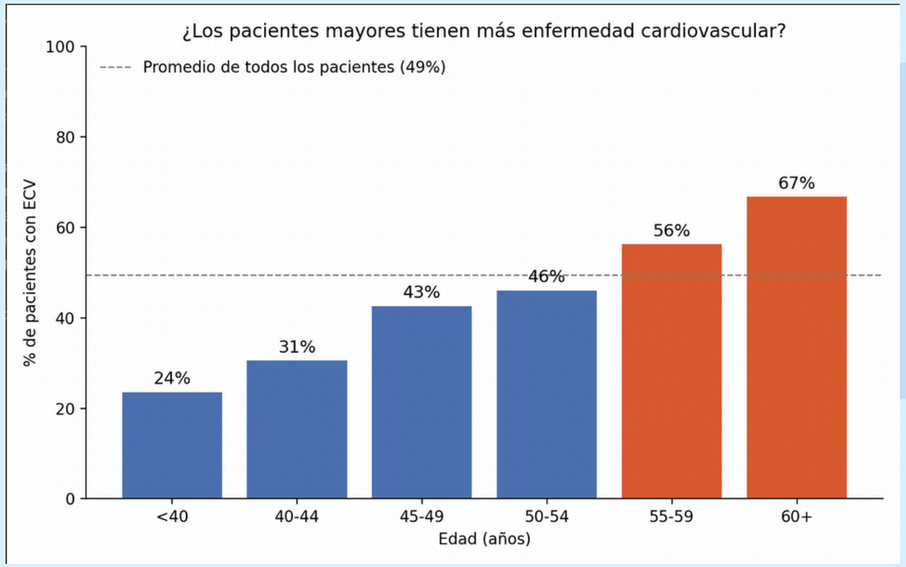
Que variables se asocian a la ECV?





% DE PACIENTES CON ECV	
Presión	22% → **78%**
Edad	24% → **67%**
Colesterol	44% → **76%**
IMC	40% → **69%**

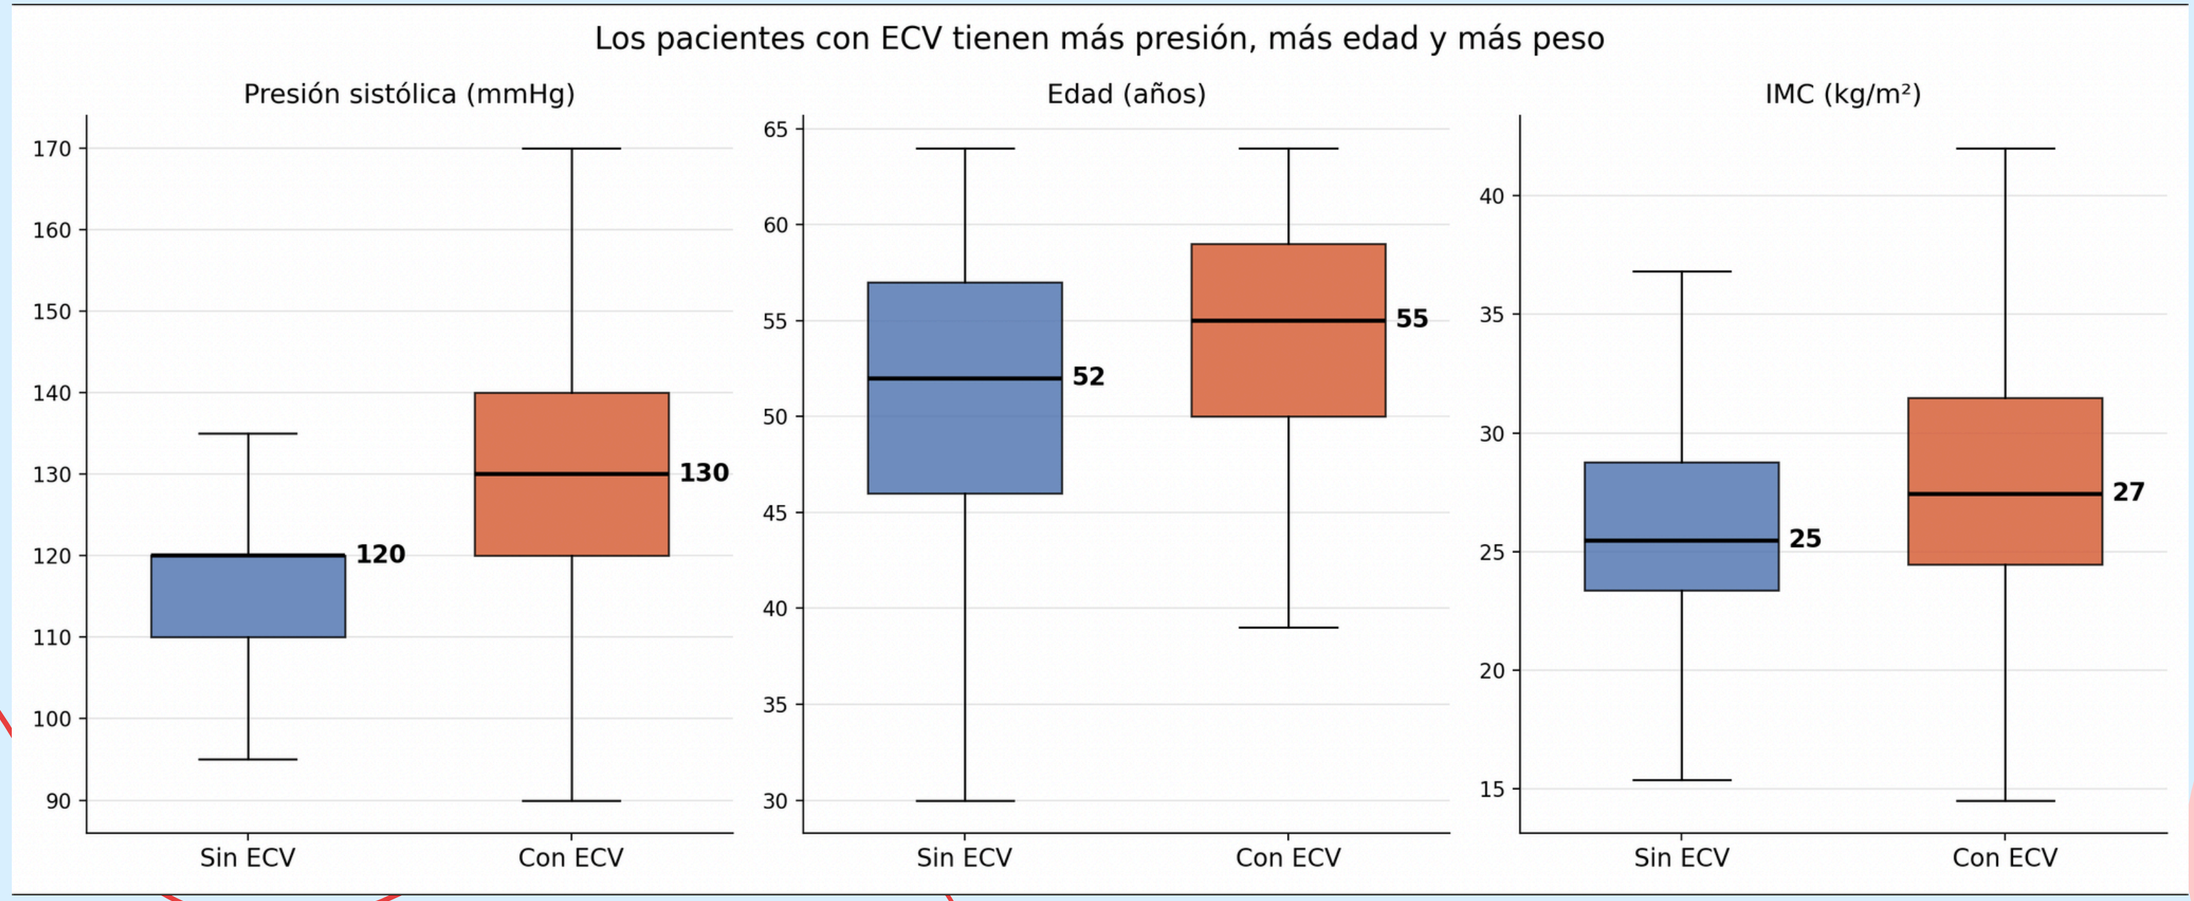




Sanos vs. Enfermos

Los que tienen ECV tienen más presión, de 120 a 130, son unos tres años más grandes y tienen un IMC un poco más alto. La presión es la que más los separa.

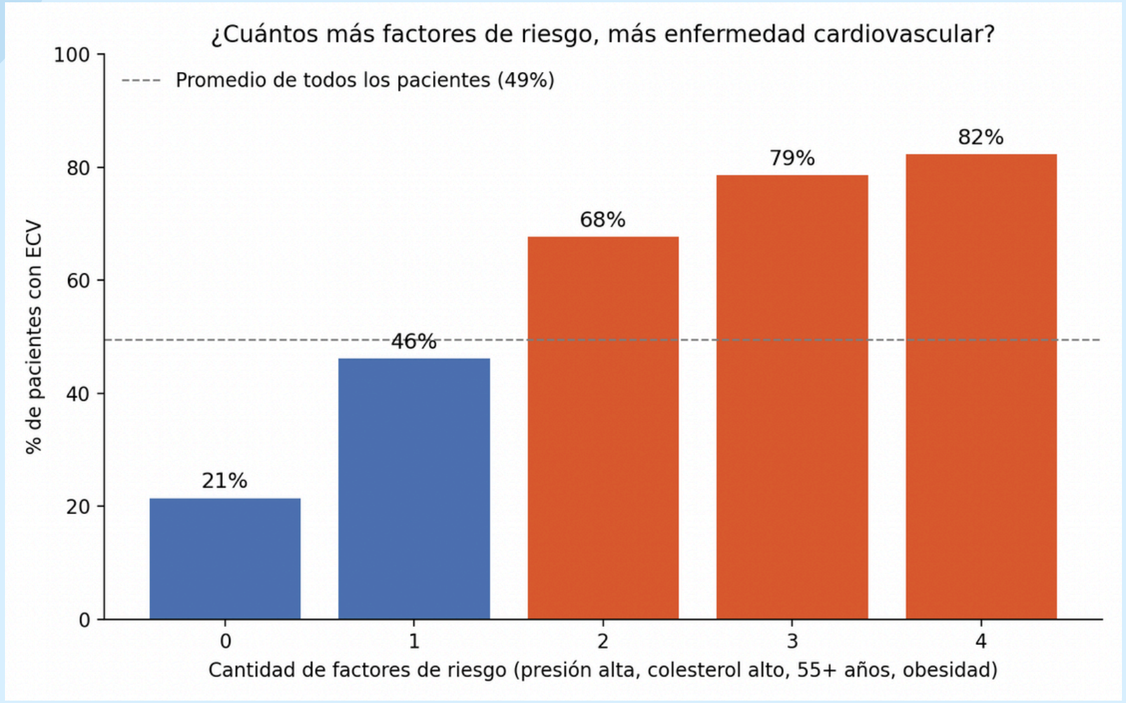
Con una sola variable no alcanza para decir si alguien está sano o enfermo.

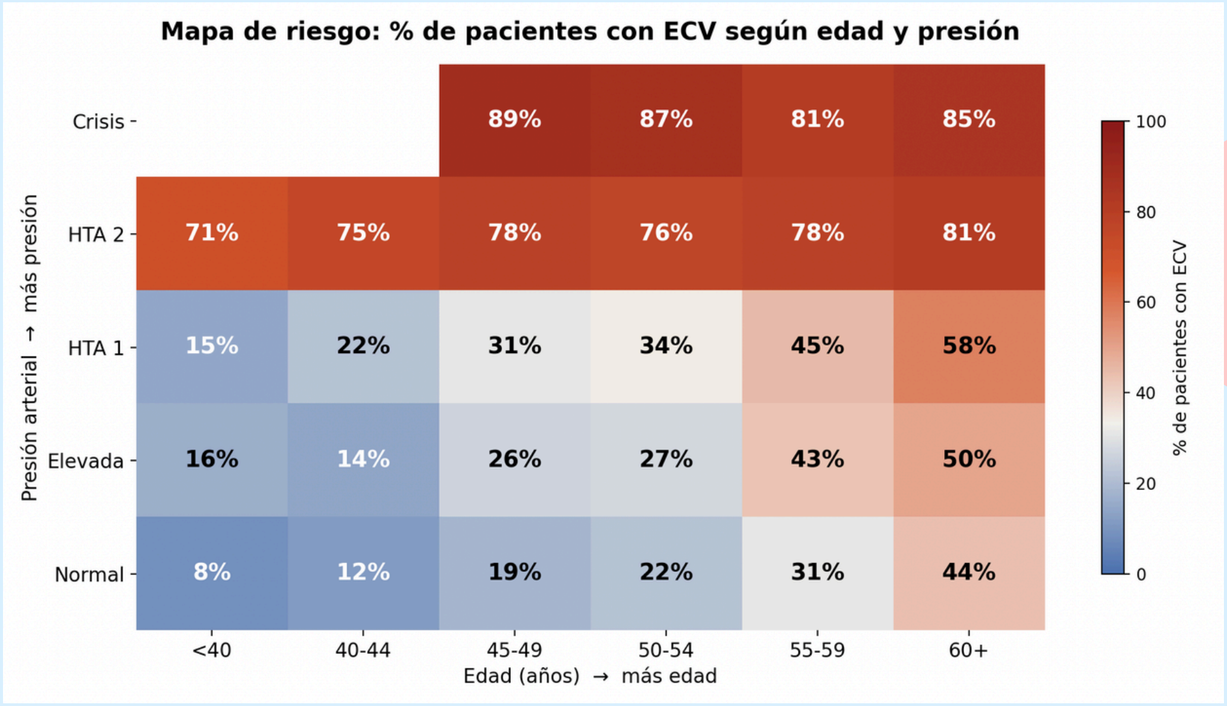


El riesgo se acumula

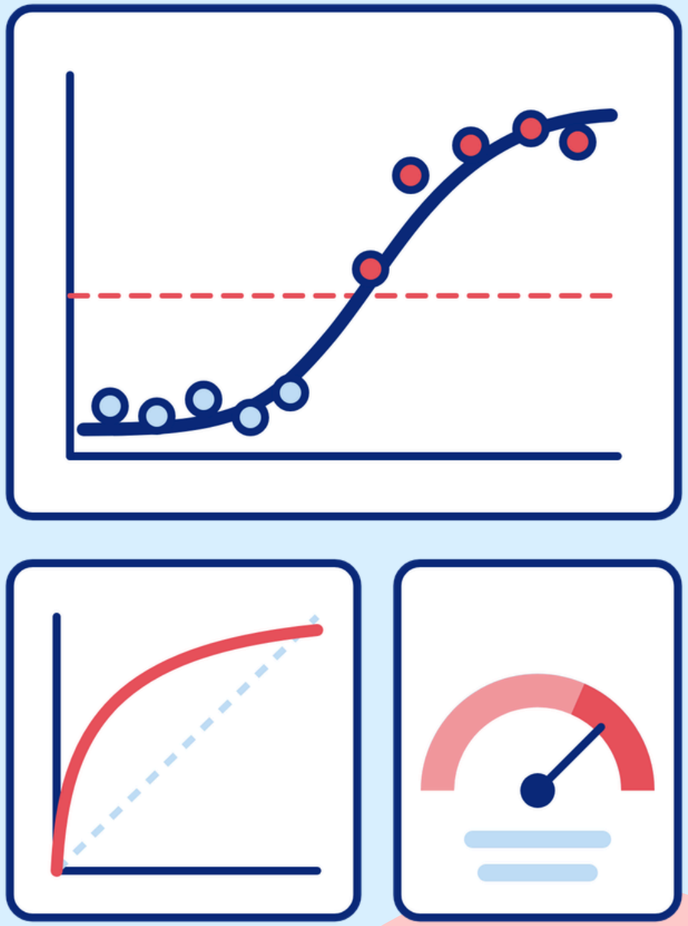
Contamos cuántos factores de riesgo tiene cada paciente: presión alta, colesterol alto, tener 55 años o más, y obesidad. Sin ningún factor, el 21% tiene ECV. Con los cuatro, el 82%.

Un paciente joven con presión normal tiene 8%. Con hipertensión alta, llega hasta 89%.





Ninguna variable sola alcanza, pero juntas sí. Por eso el siguiente paso fue armar un modelo que las combine todas.



05

Creación del modelo

¿Qué es la regresión logística?

¿Qué es?

Un modelo estadístico usado para estimar probabilidades cuando la variable que queremos predecir tiene dos posibles resultados

¿Cómo funciona?

Combina diferentes variables explicativas para calcular una probabilidad entre 0 y 1

¿Por qué la usamos?

Porque nos permite estudiar resultados binarios, como presentar o no una determinada condición clínica

Modelo de presión alta

	Modelo 1	Modelo 2
Pregunta	*¿Tiene presión alta?*	*¿Tiene presión alta? (solo enfermos)*
Y (lo que predice)	presion_alta = 1	presion_alta = 1
Pacientes	todos (68.618)	solo los que tienen ECV (33.946)
X (variables)	edad, sexo, IMC, colesterol, glucosa, fuma, alcohol	edad, sexo, IMC, colesterol, glucosa, fuma, alcohol

Presion alta: hipertension nivel 2 o crisis.
Gender: pasamos de 1-2 a 0-1 para que estuviera de la misma manera que las demas variables.

```
# ------------------------------------------------------------
# Crear modelo: todos los pacientes: ¿Lo puedo operar hoy? |
# ------------------------------------------------------------
import statsmodels.api as sm

datos_limpios["presion_alta"] = (datos_limpios["categoria_presion"] >= 5).astype(int)
datos_limpios["sexo"] = (datos_limpios["gender"] == 2).astype(int)  # 0 = mujer, 1 = hombre

variables_x = ["age_number", "sexo", "imc", "cholesterol", "gluc", "smoke", "alco"]
X = sm.add_constant(datos_limpios[variables_x])
y = datos_limpios["presion_alta"]

modelo = sm.Logit(y, X).fit()
datos_limpios["prob_presion_alta"] = modelo.predict(X)
print(modelo.summary())

# tabla final modelo todos los pacientes
tabla_final_pacientes = datos_limpios[["id", "presion_alta", "prob_presion_alta"]]
print(tabla_final_pacientes.head())
```

```
# ------------------------------------------------------------
# Crear modelo: pacientes con ECV: ¿Lo puedo operar hoy? |
# ------------------------------------------------------------
datos_ecv = datos_limpios[datos_limpios["cardio"] == 1].copy()

X_ecv = sm.add_constant(datos_ecv[variables_x])
y_ecv = datos_ecv["presion_alta"]

modelo_ecv = sm.Logit(y_ecv, X_ecv).fit()
datos_ecv["prob_presion_alta"] = modelo_ecv.predict(X_ecv)
print(modelo_ecv.summary())

# tabla final modelo pacientes con ECV
tabla_final_ecv = datos_ecv[["id", "presion_alta", "prob_presion_alta"]]
print(tabla_final_ecv.head())
```

	id	presion_alta	prob_presion_alta
✅ 0	0	0	0.215416
✅ 1	1	1	0.676544
✅ 2	2	0	0.389163
❌ 3	3	1	0.317433
✅ 4	4	0	0.165465

Optimization terminated successfully.

Que predice el modelo?

Usa todos los pacientes

Cuantas variables se usan para predecir

Cuanto explica el modelo?

Si < 0,05: el modelo sirve en conjunto

Logit Regression Results

Dep. Variable:	presion_alta	No. Observations:	68618
Model:	Logit	Df Residuals:	68610
Method:	MLE	Df Model:	7
Date:	Wed, 11 Nov 2026	Pseudo R-squ.:	0.07887
Time:	23:01:44	Log-Likelihood:	-40637.
converged:	True	LL-Null:	-44117.
Covariance Type:	nonrobust	LLR p-value:	0.000

	coef	std err	z	P>|z|	[0.025	0.975]
const	-5.9669	0.084	-70.754	0.000	-6.132	-5.802
age_number	0.0401	0.001	30.716	0.000	0.038	0.043
sexo	0.2992	0.019	15.780	0.000	0.262	0.336
imc	0.0900	0.002	53.227	0.000	0.087	0.093
cholesterol	0.4811	0.014	35.370	0.000	0.454	0.508
gluc	-0.0897	0.016	-5.543	0.000	-0.121	-0.058
smoke	0.0882	0.033	2.707	0.007	0.024	0.152
alco	0.1779	0.039	4.575	0.000	0.102	0.254

La variable se asocia a menos chances de presión alta, siempre que el resto de las variables se mantenga igual.

Si < 0,05: la variable influye

MODELO 1

MODELO 2

Que predice el modelo?

Usa solo los pacientes enfermos

	id	presion_alta	prob_presion_alta
✅ 1	1	1	0.691942
❌ 2	2	0	0.519911
✅ 3	3	1	0.558642
✅ 7	12	1	0.617834
❌ 15	24	0	0.698906

```
         Current function value: 0.669672
         Iterations 5
                           Logit Regression Results
==============================================================================
Dep. Variable:           presion_alta   No. Observations:                33946
Model:                          Logit   Df Residuals:                    33938
Method:                          MLE   Df Model:                            7
Date:               Wed, 11 Nov 2026   Pseudo R-squ.:                 0.02923
Time:                       23:01:44   Log-Likelihood:                -22733.
converged:                     True   LL-Null:                       -23417.
Covariance Type:           nonrobust   LLR p-value:                1.873e-291
==============================================================================
                 coef    std err          z      P>|z|      [0.025      0.975]
------------------------------------------------------------------------------
const         -1.7762      0.115    -15.476      0.000      -2.001      -1.551
age_number    -0.0036      0.002     -2.018      0.044      -0.007      -0.000
sexo           0.2086      0.025      8.397      0.000       0.160       0.257
imc            0.0651      0.002     29.530      0.000       0.061       0.069
cholesterol    0.2011      0.016     12.380      0.000       0.169       0.233
gluc          -0.0971      0.020     -4.876      0.000      -0.136      -0.058
smoke          0.2156      0.045      4.777      0.000       0.127       0.304
alco           0.3432      0.055      6.184      0.000       0.234       0.452
==============================================================================
```

Cuantas variables se usan para predecir

Cuanto explica el modelo?

Si < 0,05: el modelo sirve en conjunto

Si < 0,05: la variable influye

Comparación entre modelos

Importar funcion que calcula el AUC

Calcula AUC del modelo 1, comparando realidad con el modelo

Calcula AUC del modelo 2, comparando realidad con el modelo

```
# ----------------------------------
# Comparación entre los dos modelos|
# ----------------------------------
from sklearn.metrics import roc_auc_score

auc_total = roc_auc_score(y, datos_limpios["prob_presion_alta"])
auc_ecv = roc_auc_score(y_ecv, datos_ecv["prob_presion_alta"])
print(f"Todos: n={len(datos_limpios)} | pseudo R²={modelo.prsquared:.4f} | AUC={auc_total:.3f}")
print(f"Con ECV: n={len(datos_ecv)} | pseudo R²={modelo_ecv.prsquared:.4f} | AUC={auc_ecv:.3f}")
```

```
Todos: n=68618 | pseudo R²=0.0789 | AUC=0.694
Con ECV: n=33946 | pseudo R²=0.0292 | AUC=0.622
```

El pseudo R² muestra que incluir las variables mejora muy poco al modelo respecto de no usar ninguna. Como referencia, en este tipo de modelos se considera bueno un valor entre 0,2 y 0,4.

	Modelo 1	Modelo 2
Pacientes	68,618	33,946
Pseudo R	0.0789	0.0292
AUC	0.694	0.622

El modelo 1 explica alrededor de un 8%

El modelo 2 explica alrededor de un 3%

El modelo llega al 62%

El modelo 1 ordena bien el 69% de los pares de pacientes

Comparación entre modelos

==> Los dos modelos son debiles.

AUC de 0,5 es al azar (1 es perfecto)

- *0,69 y 0,62 estan cerca.*
- *Edad, sexo, IMC, colesterol, glucosa, tabaco y alcohol casi no pueden predecir quien tiene presion alta.*

El segundo modelo es peor y usa la mitad de los pacientes.

	Modelo 1	**Modelo 2**
Pacientes	68,618	33,946
Pseudo R	0.0789	0.0292
AUC	0.694	0.622

Modelo final: cardio

¿Que predice?
Y = CARDIO (0/1)

1 = posee una enfermedad cardiovascular

0 = no tiene enfermedad

datos = 68.618

Datos del paciente

age_number, sexo, imc

Habitos y mediciones

cholesterol, gluc, smoke, alco

Presiones (nuevas variables)

ap_hi, ap_lo

```
# ----------------------------------
# Crear modelo cardio: ¿Tiene ECV? |
# ----------------------------------
variables_cardio_x = ["age_number", "sexo", "imc", "cholesterol", "gluc", "smoke", "alco", "ap_hi", "ap_lo"]

X_cardio = sm.add_constant(datos_limpios[variables_cardio_x])
y_cardio = datos_limpios["cardio"]

modelo_cardio = sm.Logit(y_cardio, X_cardio).fit()
datos_limpios["prob_cardio"] = modelo_cardio.predict(X_cardio)
print(modelo_cardio.summary())

# tabla final modelo pacientes
tabla_final_cardio = datos_limpios[["id", "cardio", "prob_cardio"]]
print(tabla_final_cardio.head())

print(f"AUC cardio: {roc_auc_score(y_cardio, datos_limpios['prob_cardio']):.3f}")
```

Logit Regression Results

Dep. Variable:	cardio	No. Observations:	68618
Model:	Logit	Df Residuals:	68608
Method:	MLE	Df Model:	9
Date:	Wed, 11 Nov 2026	Pseudo R-squ.:	0.1900
Time:	16:30:05	Log-Likelihood:	-38522.
converged:	True	LL-Null:	-47559.
Covariance Type:	nonrobust	LLR p-value:	0.000

	coef	std err	z	P>|z|	[0.025	0.975]
const	-11.9536	0.121	-98.709	0.000	-12.191	-11.716
age_number	0.0507	0.001	37.582	0.000	0.048	0.053
sexo	0.0328	0.020	1.672	0.095	-0.006	0.071
imc	0.0276	0.002	15.293	0.000	0.024	0.031
cholesterol	0.4955	0.016	31.756	0.000	0.465	0.526
gluc	-0.1189	0.018	-6.719	0.000	-0.154	-0.084
smoke	-0.1472	0.035	-4.237	0.000	-0.215	-0.079
alco	-0.2251	0.042	-5.319	0.000	-0.308	-0.142
ap_hi	0.0562	0.001	60.473	0.000	0.054	0.058
ap_lo	0.0113	0.001	7.731	0.000	0.008	0.014

	Y = presion_alta	Y = cardio
Pseudo R^2	0.079	**0.190**

el modelo mejora un 19 % respecto de no usar ninguna variable

Variable	coef	Odds ratio	Lectura
ap_hi	0.0562	≈ 1.06	Cada mmHg más de sistólica sube ~6% las chances de ECV. Por cada 10 mmHg son ~75% más.
ap_lo	0.0113	≈ 1.01	Efecto chico.
age_number	0.0507	≈ 1.05	Cada año suma ~5%.
cholesterol	0.4955	≈ 1.64	Cada nivel más sube ~64%.
imc	0.0276	≈ 1.03	Cada punto suma ~3%.
sexo	0.0328	≈ 1.03	**No significativa** (p = 0.095)
gluc	-0.1189	≈ 0.89	Signo negativo.
smoke	-0.1472	≈ 0.86	Signo negativo.
alco	-0.2251	≈ 0.80	Signo negativo.

odds ratio = e^(coeficiente × unidades)

```
# ----------------------------------
# Crear modelo cardio: ¿Tiene ECV? |
# ----------------------------------
variables_cardio_x = ["age_number", "sexo", "imc", "cholesterol", "gluc", "smoke", "alco", "ap_hi", "ap_lo"]

X_cardio = sm.add_constant(datos_limpios[variables_cardio_x])
y_cardio = datos_limpios["cardio"]

modelo_cardio = sm.Logit(y_cardio, X_cardio).fit()
datos_limpios["prob_cardio"] = modelo_cardio.predict(X_cardio)
print(modelo_cardio.summary())

# tabla final modelo pacientes
tabla_final_cardio = datos_limpios[["id", "cardio", "prob_cardio"]]
print(tabla_final_cardio.head())

print(f"AUC cardio: {roc_auc_score(y_cardio, datos_limpios['prob_cardio']):.3f}")
```

	id	cardio	prob_cardio
0	0	0	0.210498
1	1	1	0.885439
2	2	1	0.676877
3	3	1	0.774815
4	4	0	0.093968

ESCALA

- 0,5: azar
- 1: perfecto
- 0,7 a 0,8: aceptable
- 0,8 a 0,9: bueno

	Y = presion_alta	Y = cardio
AUC	0.694	**0.790**

El modelo le asigna una probabilidad de enfermedad más alta al paciente realmente enfermo que al sano en 79 de cada 100 comparaciones

AUC cardio: 0.790

Predecir presión alta

Pseudo R^2 = 0,029

AUC = 0,622

Predecir ECV

Pseudo R^2 = 0,190

AUC 0,790

No se pueden comparar exactamente (miden cosas distintas), pero sirve de orientación.

Evaluación del modelo final

Dividimos los datos para evaluar cómo funciona el modelo con pacientes que no usó durante su entrenamiento

ENTRENAMIENTO
Aprender patrones

PRUEBA
Evaluar predicciones



AUC del modelo con datos completos

0,790

AUC del modelo con datos de prueba

0,791

El modelo mantiene un rendimiento similar al evaluar con datos que no habia usado para etrenar

¿Cómo evaluamos las predicciones?

Usamos una matriz de confusión para comparar las predicciones del modelo con la situacion real de los pacientes

	Sin ECV	**Con ECV**
Sin ECV	*Verdadero negativo*	***Falso positivo***
Con ECV	***Falso negativo***	Verdadero positivo

Sensibilidad (recall)

De todos los pacientes que realmente tienen ECV ¿qué porcentaje detecta el modelo?

Exactitud (accuracy)

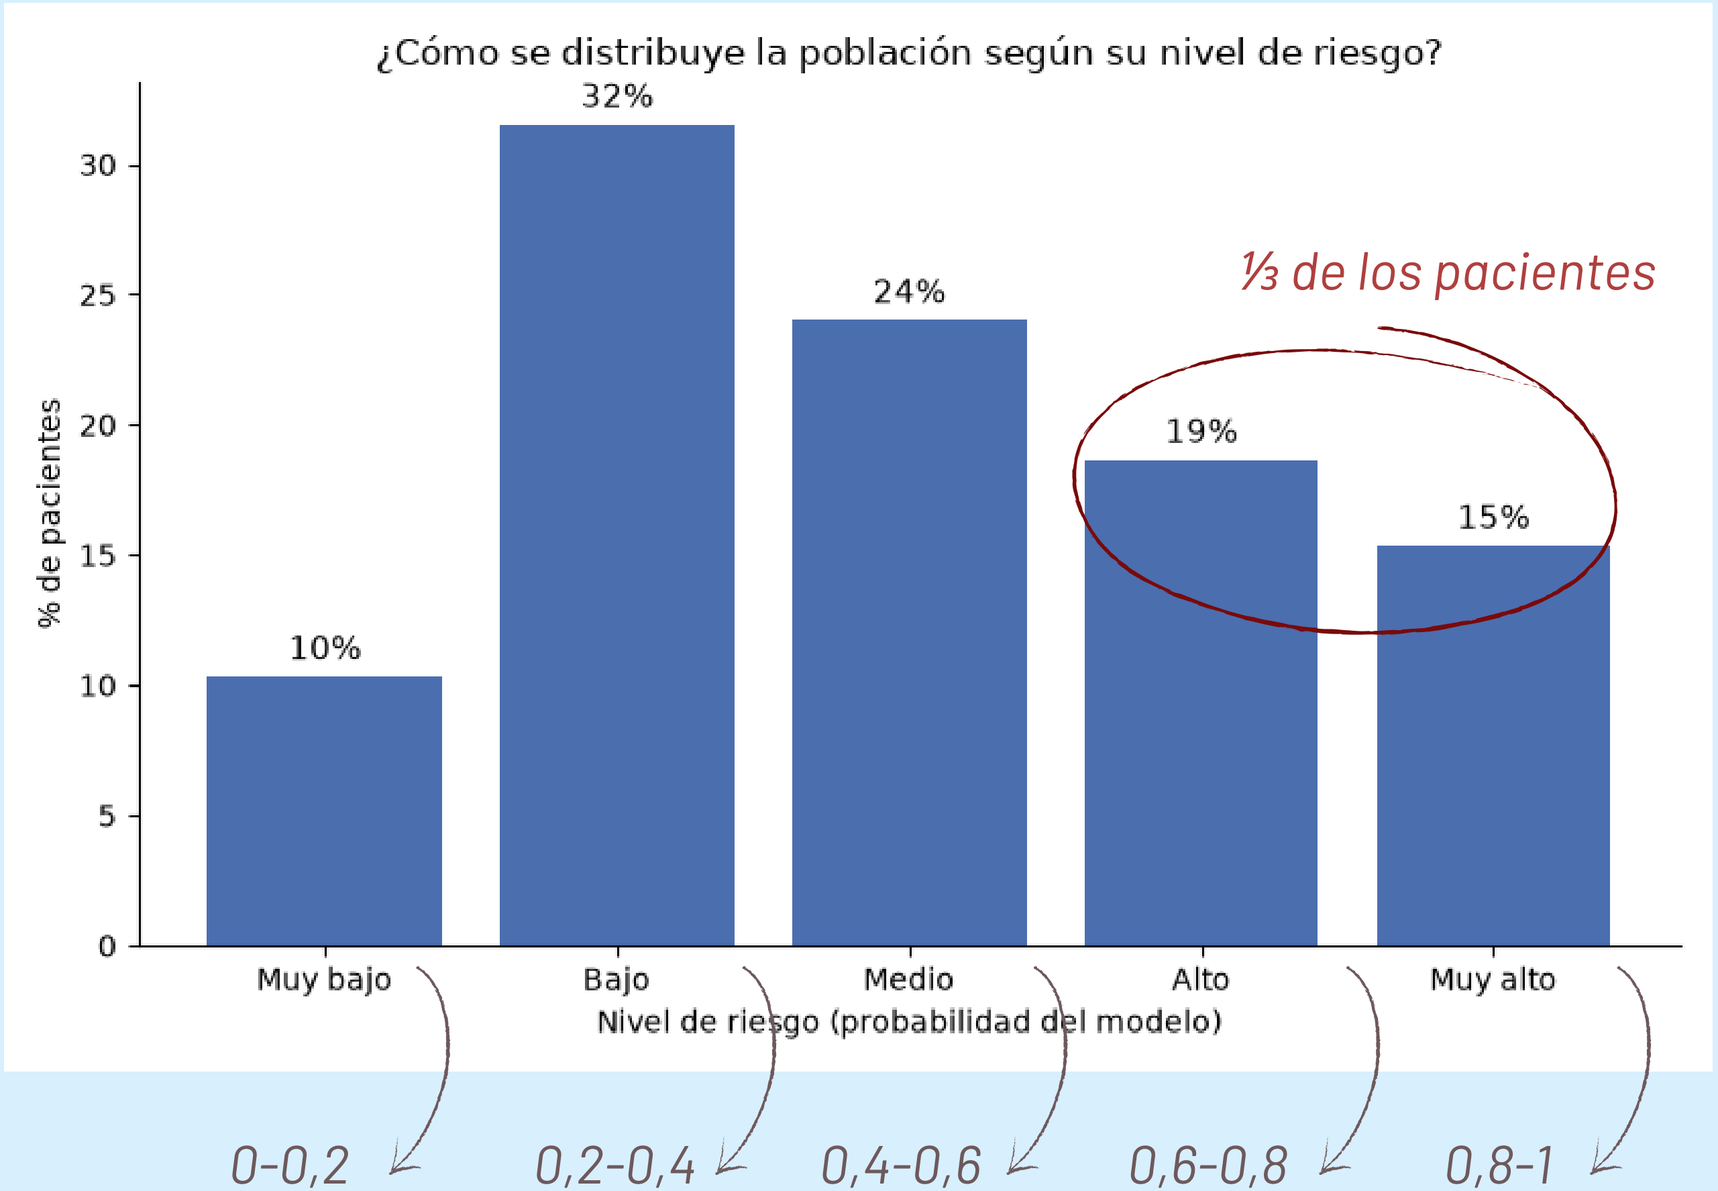
Del total de pacientes ¿qué porcentaje clasifica correctamente el modelo?

Comparamos dos umbrales para determinar cómo cambiaban las clasificaciones del modelo

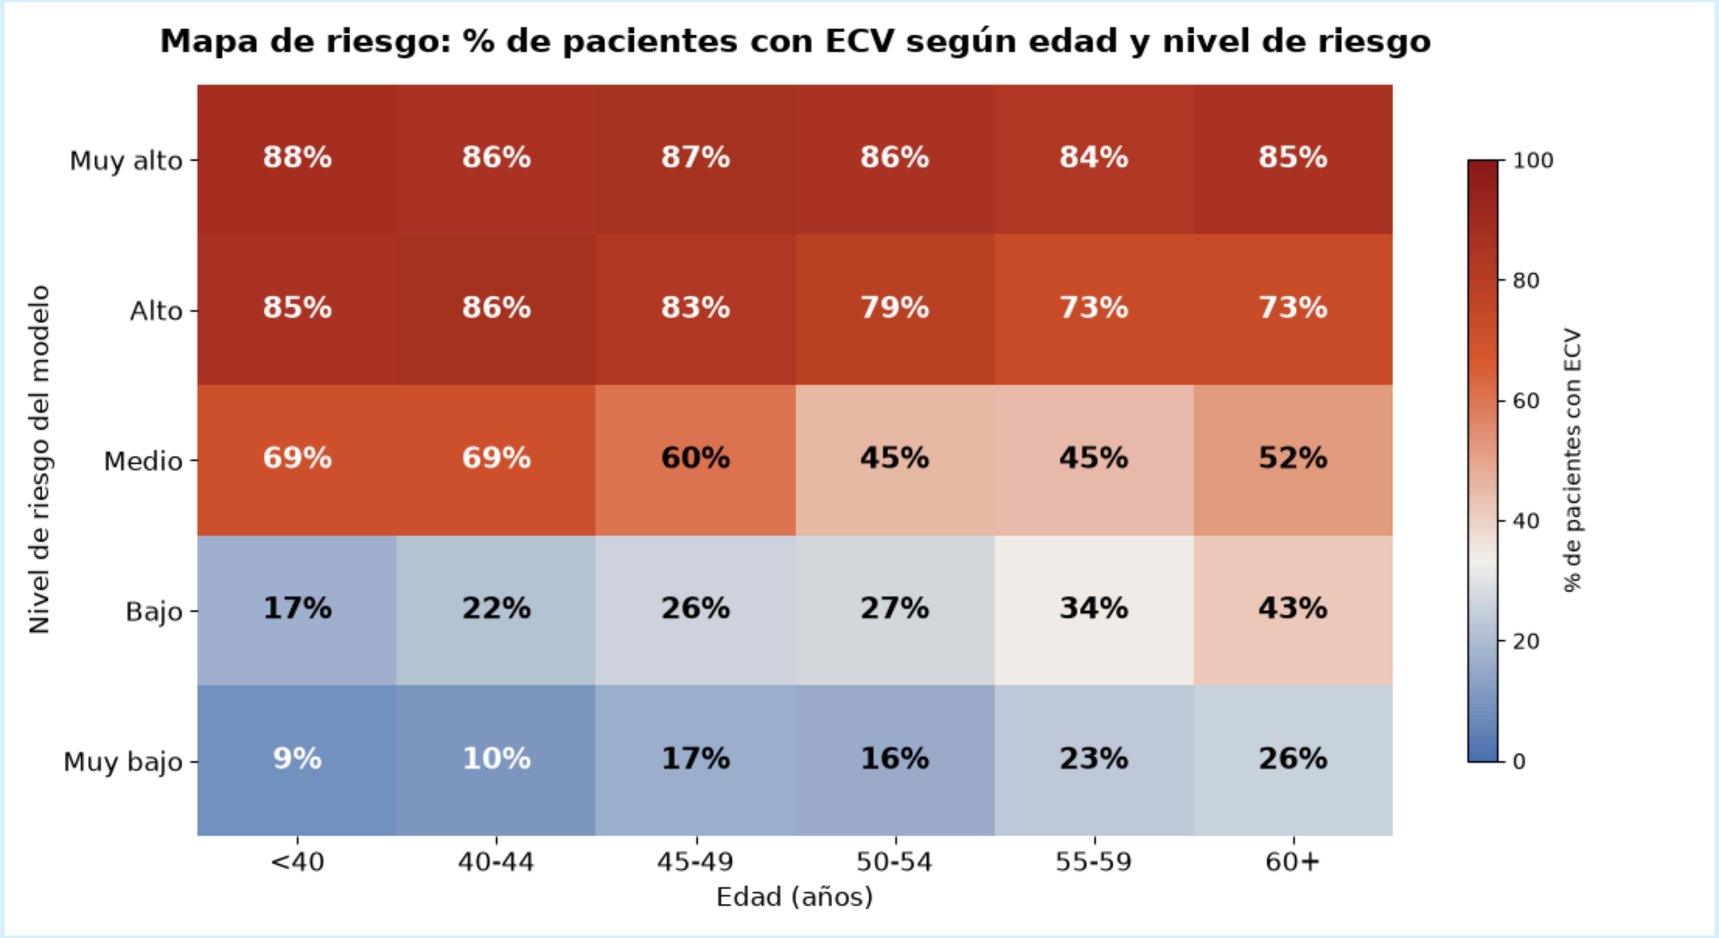
	Corte 0,5	**Corte 0,4**
Falsos negativos	3,435	**2,068**
Falsos positivos	2,153	**3,795**
Sensibilidad	66%	**80%**
Exactitud	73%	**72%**

Decisión: usar el corte de 0,4

Detectamos más pacientes con ECV, aceptando un mayor número de falsas alarmas.


¿Cómo se distribuye la población según su nivel de riesgo?
% de pacientes
0
5
10
15
20
25
30
10%
32%
24%
19%
15%
Muy bajo
Bajo
Medio
Alto
Muy alto
Nivel de riesgo (probabilidad del modelo)
⅓ de los pacientes
0-0,2
0,2-0,4
0,4-0,6
0,6-0,8
0,8-1

+ riesgo



+ riesgo



06

Conclusiones y limitaciones

Conclusiones

¿Es posible identificar patrones en los datos clínicos y de estilo de vida que permitan predecir la presencia de una ECV?

Sí. Con presión, edad, colesterol e IMC el modelo detecta 8 de cada 10 pacientes con ECV (AUC 0,79)

La presión es la clave
De 22% con ECV (normal) a 78% (HTA 2)

El riesgo se acumula
De 21% sin factores a 82% con los cuatro

Los hábitos casi no diferencian
Fumar, alcohol y actividad: entre 47% y 53%

El modelo ordena el riesgo
Riesgo muy bajo: 14% con ECV. Muy alto: 85%

Son factores medibles y prevenibles: el modelo ayuda a priorizar pacientes, no reemplaza el diagnóstico

Limitaciones

Informacion limitada
Faltan antecedentes médicos y datos más detallados sobre los hábitos

Resultados inesperados
Algunas variables mostraron relaciones que no pudimos explicar completamente

Errores de predicción
El modelo todavía presenta falsos positivos y falsos negativos

Validación limitada
No probamos el modelo con datos de otras poblaciones



Gracias!